

Robot Operating System Baseado em Interface Cérebro-Máquina

Fabricio T. Leite¹, Lucas de O. Dutra¹

¹Centro universitário FACENS

Rodovia Senador José Ermírio de Moraes, 1425 - Sorocaba - São Paulo - Brazil

fabricio.torquatol@gmail.com, lucas_o_dutra@hotmail.com

Abstract. *The brain computer interface system is a computer paradigm with neuroscience to develop an application based on systems control, using devices to capture brain signals. Artificial Neural Networks are machine learning studies that have the ability to adapt and learn to a activity or behavior from a information's set. Objective this work is propose a Recurrent Neural Network model controlling's able a virtual object from the Robot Operating System. The control system this work is a, voluntary motor actions of the hands, where the user performed a motor action with the left or right hand so that a virtual model rotated to the corresponding direction, in case the user did not any motor action, the virtual model would move forward, for that an electroencephalogram was used as the acquisition devices. The result of this work comprises a performance evaluation of four types of recurrent neural networks along with the metrics of the test applied to the user in the control platform.*

Resumo. *Um sistema de interface cérebro-máquina é um paradigma da computação com a neurociência para desenvolver uma aplicação baseada em controle de sistemas, utilizando equipamentos de captura de sinais cerebrais. As Redes Neurais Artificiais são ferramentas de Inteligência Artificial que possuem a capacidade de se adaptar e de aprender a realizar uma certa tarefa ou comportamento a partir de um conjunto de informações. Este trabalho tem como objetivo propor um modelo de Rede Neural Recorrente capaz de controlar um objeto virtual construído a partir do Robot Operating System. Para o sistema desse trabalho foram utilizadas, como função de controle, ações motoras voluntárias das mãos, onde o usuário realizava uma ação motora com a mão esquerda ou direita de modo que o modelo virtual rotacionava para a direção correspondente, caso o usuário não realizasse nenhuma ação motora, o modelo virtual iria se locomover para a frente, para isso foi utilizado um eletroencefalograma como equipamento de aquisição. O resultado deste trabalho compreende uma avaliação de desempenho de quatro tipos de redes neurais recorrentes junto com as métricas do teste aplicado ao usuário na plataforma de controle.*

1. Introdução

A tecnologia está em constante evolução, disponibilizando novas possibilidades e horizontes para serem estudados. De modo, que os avanços na ciência permitiram a existência de energia elétrica dentro das residências, a comunicação entre pessoas independente da distância e, também, a identificação das doenças de forma rápida e precisa.

Ao observar os estudos de novas tecnologias, uma das áreas que obteve peculiar progresso foi a inclusão social. Segundo os dados do Instituto Brasileiro de Geografia e Estatística [IBGE 2013], 6,9% dos brasileiros declararam ter algum tipo de deficiência; a Pesquisa Nacional de Saúde (PNS) analisou deficiência visual, auditiva, motora e mental/intelectual.

Existem diversas tecnologias para auxiliar pessoas com alguma deficiência, como os aplicativos que leem os textos dos computadores, as próteses mecânicas/biônicas e aparelhos auditivos. Conforme as causas sociais ganham força ao redor do mundo, e novos investimentos são direcionados para a inovação e aplicação de tecnologias voltadas para essa área, torna-se fundamental que pesquisas e desenvolvimento sejam feitos para beneficiar, cada vez mais, esse público.

Segundo Carlos Roberto França, a ocorrência de deficiências motoras no Brasil é considerável, devido que dos 6,9% dos brasileiros registrados pela pesquisa do IBGE, pelo menos 1,3% da população têm algum tipo de deficiência física e quase a metade desse total (46,8%) tem grau intenso ou muito intenso de limitações, de modo que se torna o maior grupo apontado pela pesquisa [França et al. 2005].

Um equipamento que pode ser utilizado nessas pesquisas é o eletroencefalograma (EEG), um sensor de monitoramento não invasivo que analisa a atividade elétrica cerebral espontânea, mesmo geralmente utilizado para detectar doenças psiquiátricas e neurológicas como epilepsia, lesões cerebrais, tumores cerebrais, está sendo um dos equipamentos que mais possuem resultados em pesquisas com interface cérebro-maquina ou do inglês brain computer interface (BCI).

Como exemplo de trabalhos de BCI com uso do EEG com a robótica temos o trabalho de Bongjae Choi e Sungho Jo "A low-cost EEG system-based hybrid brain-computer interface for humanoid robot navigation and recognition" [Choi and Jo 2013] e como exemplo de trabalhos de BCI virtuais utilizando o EEG temos "Designing a brain-computer interface controlled video-game using consumer grade EEG hardware" [van Vliet et al. 2012].

Este trabalho tem o objetivo de propor um modelo de sistema de controle a partir de brain computer interface (BCI) utilizando um dispositivo EEG. Em uma primeira parte, uma análise foi realizada em cima de quatro tipos de arquiteturas de redes neurais artificiais (RNA), de modo que a arquitetura que obtivesse melhor desempenho seria utilizada como fonte do trabalho para o desenvolvimento de uma interface para identificar a ação motora do usuário e transmitir como forma de comando para o sistema. Entre os comandos escolhidos para a elaboração deste trabalho estão: mover para a frente, rotacionar para a esquerda e rotacionar para a direita.

O restante deste artigo está organizado da seguinte forma: na Seção 2 é abordado o referencial teórico para contextualizar a cerca dos trabalhos desenvolvidos na área; na Seção 3, é abordado a proposta do trabalho em como realizar o tratamento, pre-processamento e classificação dos dados para fazer a predição das ações motoras, finalmente, na Seção 4, são discutidos os resultados e trabalhos futuros.

2. Referencial Teórico

Utilizando a evolução tecnológica da Computação como base de sustentação, a Neurociência conseguiu ter um rápido avanço em sua área de estudo. Um exemplo de trabalho nesse campo é a percepção de que cada área do cérebro humano é responsável por executar diferentes funções do corpo, tais como: motricidade, afetividade e cognição [de Souza et al. 2015].

De modo assíncrono a esse avanço surgiu a área de estudo chamada Brain Computer Interface (BCI), propondo estudar a capacidade de indivíduos em usar a atividade do cérebro para mover dispositivos. Segundo Gerwin Schalk [Schalk et al. 2004] esses estudos mensuram características específicas da atividade cerebral e como fazer suas traduções em sinais de controle de dispositivos.

Atualmente, as pesquisas de BCI vêm crescendo de forma gradativa, desenvolvendo diversos trabalhos voltados para acessibilidade. Como os trabalhos de Kretikouski Roque e Paulo Cezar "Controle de um protótipo de cadeira de rodas através de uma interface cérebro-computador" [Roque et al. 2017], Werley de Oliveira Gonçalves com o trabalho "Estudo dos sinais de eletroencefalograma e eletrodermal no aprendizado por reforço de uma interface cérebro-máquina" [GONÇALVES et al. 2017].

Além disso, também são encontrados trabalhos voltados para inclusão social, como o trabalho acadêmico de Regina de O. Heidrich "Jogos Digitais Para Interação Com Brain Computer Interface Para Auxiliar No Processo De Inclusão Escolar De Pessoas Com Paralisia" Cerebral [Heidrich et al. 2016].

Observa-se que os trabalhos citados acima utilizaram o mesmo sensor de captura de dados, o eletroencefalograma, dispositivo não invasivo de aquisição de sinais que distribui eletrodos no escalpo e através deles realiza o registro da atividade eletrofisiológica do cérebro.

Assim, este trabalho apresenta quatro abordagens de arquiteturas diferentes de RNN, de modo a resolver o problema de predição de ações motoras voluntárias baseadas em sistema de controle BCI.

3. Materiais e Métodos

Com o intuito de validar o sistema de BCI proposto no trabalho, apresenta-se, nesta seção, uma experiência utilizando-se de teste de usabilidade aplicado a um modelo desenvolvido a partir de pré-processamento, extração de características e classificação.

Nas seções seguintes será esclarecido como foi realizado os principais pontos sobre a aquisição dos sinais do EEG, o pré-processamento dos dados e o desenvolvimento do modelo classificatório. Em seguida, será apontado os métodos para medição de desempenho das arquiteturas de redes propostas. Finalmente, será apresentado o protocolo realizado no teste de usabilidade com a plataforma do Robot Operating System (ROS).

3.1. Aquisição de Sinais

Para a realização da captura dos impulsos cerebrais foi utilizado um eletroencefalograma EMOTIV EPOC+ 14 Channel, da empresa EMOTIV (figura 1). Este equipamento possui uma frequência de amostragem de 128 Hz com conversor analógico-digital de 16

bits com 14 canais de eletrodos: AF3 F7 F3 FC5 T7 P7 O1 O2 P8 T8 FC6 F4 F8 AF4 [Emotiv 2019].

Figura 1. EMOTIV EPOC+ 14 Channel



Fonte: [Emotiv 2019]

Para transmissão e captura dos dados obtidos pelo equipamento para o computador utilizou-se a biblioteca de código fonte aberto EMOKIT [Brocious and Machulis 2019].

3.2. Pré-Processamento de Dados

Foi necessário fazer uma limpeza dos dados coletados para serem filtrados através de algoritmos de processamento de sinais, para então passar por um procedimento de cálculos que resultaria em um conjunto de valores usados no modelo de classificação.

Para um melhor entendimento de como foi realizada essa etapa, é necessário algumas notações referentes aos dados extraídos do equipamento. Devido à frequência de 128 Hz e os 14 canais do EEG a entrada desse procedimento é uma matriz de 128x14. Ao passar essa matriz pelo algoritmo de Fast Fourier Transform (FFT) [Brigham and Brigham 1988] com faixa de frequência de 0 a 30 Hz resulta-se numa matriz de 30x14 no domínio da frequência.

Desse modo, os dados passam por uma separação das frequências por faixas de ondas cerebrais, como demonstrado na tabela 1 segundo [Capela and Georgieva 2012].

Tabela 1. Classificação das Ondas Eletroencefalográficas em Bandas de Frequências

Delta (0-4 Hz)	Vigília com estado de sono profundo, meditação, ações involuntárias e estado inconsciente.
Teta (4-8 Hz)	Vigília com estado de atenção forçada (concentração), resolução de problemas lógicos e processamento de memórias.
Alfa (8-12 Hz)	Vigília com relaxamento.
Beta (12-30 Hz)	Vigília com estado de atenção.

Fonte: [Bonini-Rocha et al. 2008]

A partir dessas faixas de valores foi realizada a média ponderada e aritmética de cada onda, de modo que a matriz final seja 14x4x2.


Devido a composição do dataset ser baseado em ondas de impulsos cerebrais, faz sentido o mesmo ser interpretado como características temporais. Por esse motivo, foi escolhido a Recurrent Neural Network (RNN) para realizar o reconhecimento dos padrões.

Dessa forma, o modelo tem como objetivo aprender quais as relações existentes entre estímulos nervosos capturados pelo EEG com as ações motoras voluntárias realizadas pelo usuário.

3.3. Modelo Proposto

Este trabalho apresenta um método alternativo utilizando RNA com o objetivo de explorar as características temporais encontradas no dataset, como descrito anteriormente. Em razão disto, quatro arquiteturas de uma Recurrent Neural Network foram propostas (Figura 2), de modo que aquela que obtivesse os melhores resultados em suas métricas de treinamento seriam escolhidas como modelo fonte da interface projetada.

Figura 2. Arquitetura de uma RNN




Fonte: [Bishop 2006]

Recurrent Neural Network é uma classe de redes neurais que explora a natureza sequencial da sua entrada [Wu et al. 2017]. Atualmente as principais arquiteturas de RNN é a Long Short-Term Memory (LSTM) na qual sua principal célula está representada na figura 3a e a Gated Recurrent Units (GRU) que pode ser observada na figura 3b. Embora essas classes não sejam as únicas, representam as mais utilizadas para os problemas de sequência [Abadi et al. 2015].


Figura 3. Arquiteturas de Recurrent Neural Network

(a) Long Short-Term Memory



Fonte: [Chung et al. 2014]

(b) Gated Recurrent Unit



Fonte: [Chung et al. 2014]

Para encontrar a melhor configuração da RNN foram realizados testes de performance através de validação cruzada em cima de um dataset real coletado na etapa de treino da experiência de usabilidade deste projeto. Sendo que para a construção dos quatro modelos utilizou-se uma arquitetura base composta de uma RNN simples junto com a função de otimização Stochastic Adam [Kingma and Ba 2014]. Para a camada neural foi selecionado um dos seguintes métodos para cada arquitetura proposta, LSTM com duas ou quatro camadas empilhadas ou GRU com duas ou quatro camadas empilhada.

3.4. Treinamento

Com a arquitetura proposta a RNA possui uma variação de dois mil a três mil e quinhentos parâmetros, tendo em sua composição uma RNN simples (LSTM com duas ou quatro camadas e GRU com duas ou quatro camadas) ligada a uma camada full connect que vai de 11 neurônios para 3 passando por uma função de softmax loss [Liu et al. 2016]. Sendo que, para facilitar a criação das arquiteturas propostas no trabalho foi utilizado a biblioteca Pytorch [Paszke et al. 2017], na qual os números de parâmetros a serem treinados de cada modelo pode ser observado na tabela 2, onde é observado que as arquiteturas compostas pela GRU possuem uma estrutura com menos parâmetros.

Tabela 2. Tabela de comparação de número de parâmetros treináveis das RNN's

Arquitetura	Número de Parâmetros
LSMT 2	4083
LSMT 4	8435
GRU 2	3075
GRU 4	6339

Para validar qual a melhor configuração de RNN para o problema em questão foram aplicadas análises da matriz de confusão para procurar evidências de overfit ou underfit no modelo junto com o processo de validação cruzada com 60% do dataset para treinamento, 20% para teste e 20% para validação, de modo a evitar modelos especializados em apenas um tipo de classificação de dados.

Após a etapa de treinamento, o sinal é coletado, pré-processado e então apresentado ao modelo para classificar a ação motora correspondente, sendo elas: ação motora com a mão esquerda, ação motora com a mão direita ou nenhuma ação motora.

3.5. Teste

Para este trabalho, foi desenvolvido um protocolo experimental baseado em um teste que avalia duas métricas utilizadas para classificar o grau de abstração do sistema de controle construído no ROS.

A plataforma ROS é um sistema de código fonte aberto, voltado a robótica, onde possui bibliotecas e ferramentas que auxiliam no desenvolvimento de aplicações em ambiente de teste virtual [Quigley et al.]. Em razão dessas características e por ser uma plataforma de integração entre a computação e a robótica, os autores desse projeto optaram pela utilização do ROS como meio de validação de modelo em meio virtual.

Uma das ferramentas que o ROS oferece é turtlesim, um simulador de hardware que trabalha sobre uma camada abstraída de comunicação de hardware [ROS 2019].

Para uma melhor representatividade do grau de abstração do sistema de controle, ficou estabelecido como teste o controle de um modelo do turtlesim através do BCI. De forma que será instanciado um objeto estático de forma aleatória, e o objetivo do usuário deverá ser alcançar o objeto no menor tempo. Desse modo, será avaliado quanto tempo demorou para o usuário executar o procedimento e qual o caminho percorrido.

O participante do teste de usabilidade na plataforma ROS foi classificado como sem disfunções neurológicas. Sendo que o participante fez uma vez o protocolo de coleta de dados com duração de vinte e cinco minutos, comportando cinco ciclos de coletas em situações diferentes, sendo elas:

- Olhos abertos com o participante sentado;
- Olhos abertos com o participante em pé;
- Olhos fechados com o participante sentado, mas ouvindo um estilo de música de seu gosto musical;
- Olhos abertos com o participante sentado, mas ouvindo um estilo de música de seu gosto musical;
- Olhos abertos com o participante em pé respondendo um questionário de perguntas não invasivas.

Durante cada um dos ciclos de aquisição o participante visualizou as imagens retratando uma ação motora voluntária, sendo elas: uma seta para a direita que representaria ação motora da mão direita, uma seta para a esquerda que representaria ação motora da mão esquerda e um círculo que representaria nenhuma ação motora, entre cada uma das ações intercaladas foi colocado uma imagem preta, que representasse o momento onde o participante fechava os olhos sem realizar nenhuma ação.

4. Resultados e Discussões

É possível separar o experimento em três fases, sendo a primeira com a captura dos dados sob o protocolo de coleta. A segunda, o pré-processamento e geração dos modelos. E a última fase, a rodada de testes de usabilidade sob a simulação gerada pelo ROS utilizando o modelo criado como fonte de predição dos comandos enviados ao controlador. Como resultado do trabalho, foi registrado três conclusões a respeito das arquiteturas propostas ao analisar a tabela 3.

A primeira análise seria em base da GRU com quatro camadas empilhadas, onde mesmo possuindo a taxa de acurácia mais alta do experimento, seu tempo de processamento foi registrado 60.0% mais lento que a LSTM com duas camadas.

Ao analisar as arquiteturas de LSTM nota-se que a acurácia se manteve igual nos dois modelos, entretanto a rede neural composta por quatro camadas teve um aumento de aproximadamente 40% do tempo de processamento.

Em vista que se a arquitetura do trabalho possuir um tempo de processamento alto, pode ocorrer perdas quantitativas de informações durante o fluxo da BCI, a velocidade se torna um fator fundamental para o sistema de controle.

De modo que ao analisar os resultados apresentados anteriormente junto com o fator de velocidade de processamento, a melhor arquitetura na qual possui a melhor distribuição de valores na matriz de confusão (figura 4a, 4b, 5a e 5b), é a arquitetura de LSTM com duas camadas empilhadas.

Tabela 3. Tabela de comparação de resultados

Arquitetura	Tempo de Treinamento	Função de Custo	Acurácia
LSMT 2	27s	0.1422	67.0%
LSMT 4	38s	0.1214	66.0%
GRU 2	30s	0.0992	62.0%
GRU 4	69s	0.0927	68.0%

Figura 4. Matriz de confusão da LSTM


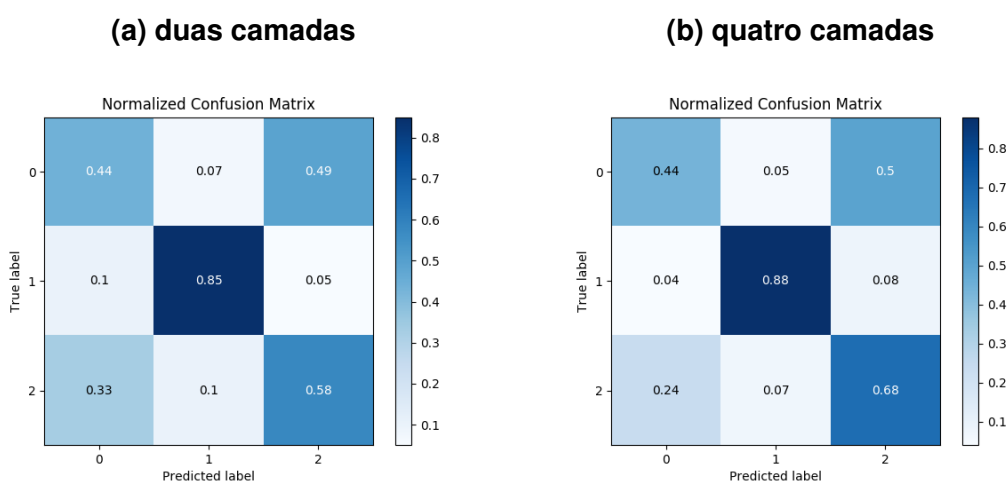


Figura 5. Matriz de confusão da GRU



Além do teste com duas e quatro camadas empilhadas, realizou-se teste com uma e com cinco camadas de modo que com essas respectivas quantidades de camadas neurais, o modelo acabou sofrendo de underfit e overfit, sendo que com uma camada o modelo estava simples e não conseguiu aprender o padrão das ondas, e com cinco camadas o modelo passou a ser especialista no dataset, devido a esses parâmetros ineficazes, suas métricas não foram colocadas sob análise dos resultados desse trabalho.

Por outro lado ao analisar a figura 4a, é possível concluir que a LSMT com duas camadas empilhadas obteve a melhor acurácia, e possuiu uma boa precisão na distinção do usuário estar ou não realizando alguma ação motora, essa conclusão é dada devido a maior taxa de precisão da matriz de confusão que são sempre os valores a se relacionarem a não execução de uma ação motora voluntária.

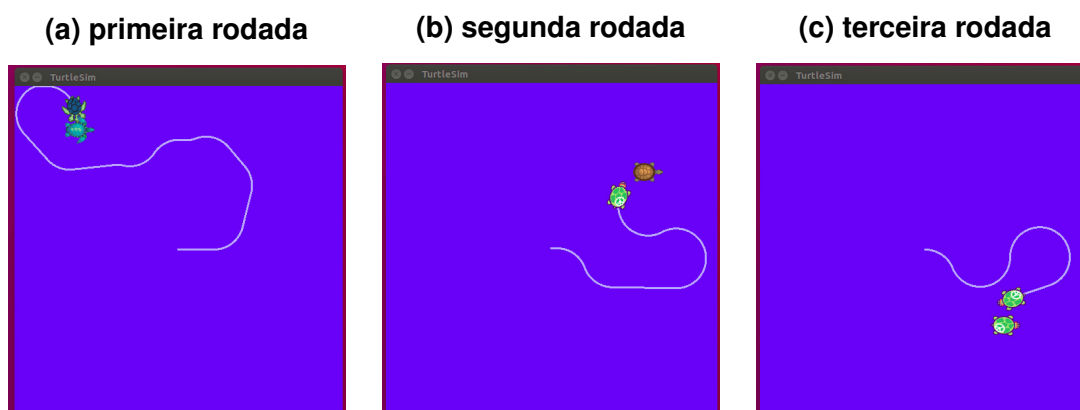
Na tabela 4 é possível observar a relação de tempo do participante em três rodadas de experimento executado. Onde é possível notar que existe uma melhora nas métricas do experimento a medida que o usuário faz teste sucessivamente, mostrando que acontece um aprendizado por parte do usuário sob a abstração do sistema de controle na interface.

Tabela 4. Resultados do tempo dos participantes para concluir o teste

ID's	Rodada 1	Rodada 2	Rodada 3
Voluntario 1	19s	13s	10s

Nas imagens 6a, 6b 6c se encontram os caminhos percorridos em cada rodada em que foi executado.

Figura 6. Caminho percorrido pelo voluntário durante o teste



É possível notar que o usuário percorre a maior parte do tempo na região onde se encontra o alvo, concluindo que existe um maior desempenho para se dirigir até o setor do objetivo, demonstrando a abstração no BCI estabelecido pelo trabalho.

5. Conclusão

Os resultados advindos deste trabalho poderão ser usados em uma implementação de BCI em qualquer meio de locomoção que atenda as características deste projeto, permitindo aumentar a adequação dos modelos e métodos já existentes, de maneira que a aplicabilidade do BCI se torne ainda mais eficiente.

De modo a contribuir com a qualidade de vida de pessoas que possuem alguma complicação nos movimentos motores, esse projeto pretende, futuramente, a reprodução desse experimento sob um sistema de controle de um protótipo real, buscando aumentar a experiencia com mais usuários e testar funções de estatísticas para séries temporais.

Referências

- Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., et al. (2015). Tensorflow: Large-scale machine learning on heterogeneous systems, 2015. *Software available from tensorflow.org*, 1(2).
- Bishop, C. M. (2006). *Pattern recognition and machine learning*. springer.
- Bonini-Rocha, A. C., Timm, M. I., Chiaramonte, M., Zaro, M., Rasia-Filho, A. A., Wolff, D., Ayres, E. d. P., and Petersen, R. D. d. S. (2008). Metodologia para observação e quantificação de sinais de eeg relativos a evidências cognitivas de aprendizagem motora. *Ciências & Cognição*, 13(2):27–50.
- Brigham, E. O. and Brigham, E. O. (1988). *The fast Fourier transform and its applications*, volume 448. prentice Hall Englewood Cliffs, NJ.
- Brocious, C. and Machulis, K. (2019). Emokit. *OpenYou*, [Online]. Available: <http://www.openyou.org>.
- Capela, N. F. and Georgieva, P. (2012). Aplicação de técnicas de aprendizagem automática para classificação de emoções humanas com sinais de eeg. *Electrónica e Telecomunicações*, 5(4):391–9.
- Choi, B. and Jo, S. (2013). A low-cost eeg system-based hybrid brain-computer interface for humanoid robot navigation and recognition. *PloS one*, 8(9):e74583.
- Chung, J., Gulcehre, C., Cho, K., and Bengio, Y. (2014). Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*.
- de Souza, J. P. G., Krizan, J., de Melo Costa, G., and de Oliveira Fermoseli, A. F. (2015). Interface cérebro-máquina (icm): Da transdução do estímulo externo em impulso nervoso a tradução em comandos digitais. *Caderno de Graduação-Ciências Biológicas e da Saúde-UNIT-ALAGOAS*, 3(1):139–152.
- Emotiv (2019). Epoc+ 14 channel - emotiv. <https://www.emotiv.com/epoc-14-channel-eeg-2/>. (Accessed on 05/12/2019).
- França, C. R., Borges, J. A., and Sampaio, F. F. (2005). Tupi-recursos de acessibilidade para educação especial e inclusiva dos deficientes motores. In *Brazilian Symposium on Computers in Education (Simpósio Brasileiro de Informática na Educação-SBIE)*, volume 1, pages 591–600.
- GONÇALVES, W. d. O. et al. (2017). Utilização dos sinais de eletroencefalograma e eletrodermal no aprendizado por reforço de uma interface cérebro-máquina.
- Heidrich, R. d. O., Branco, M. A., Mossmann, J. B., Schuh, A. R., and Jensen, E. (2016). Jogos digitais para interação com brain computer interface para auxiliar no processo de inclusão escolar de pessoas com paralisia cerebral. *Blucher Design Proceedings*, 2(9):3397–3407.
- IBGE, I. C. (2013). *Instituto Brasileiro de Geografia e Estatística - 2013*.
- Kingma, D. P. and Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- Liu, W., Wen, Y., Yu, Z., and Yang, M. (2016). Large-margin softmax loss for convolutional neural networks. In *ICML*, volume 2, page 7.

- Paszke, A., Gross, S., Chintala, S., and Chanan, G. (2017). Pytorch. *Computer software*. Vers. 0.3, 1.
- Quigley, M., Gerkey, B., Conley, K., Faust, J., Foote, T., Leibs, J., Berger, E., and EHEELER, R. Ng, a.(2009). ros: An open-source robot operating system. *Proceedings of ICRA-2009 IEEE*.
- Roque, K., Cezar, P., et al. (2017). Controle de um protótipo de cadeira de rodas através de uma interface cérebro-computador.
- ROS (2019). Turtlesim. <http://wiki.ros.org/turtlesim>. (Accessed on 05/12/2019).
- Schalk, G., McFarland, D. J., Hinterberger, T., Birbaumer, N., and Wolpaw, J. R. (2004). Bci2000: a general-purpose brain-computer interface (bci) system. *IEEE Transactions on biomedical engineering*, 51(6):1034–1043.
- van Vliet, M., Robben, A., Chumerin, N., Manyakov, N. V., Combaz, A., and Van Hulle, M. M. (2012). Designing a brain-computer interface controlled video-game using consumer grade eeg hardware. In *2012 ISSNIP Biosignals and Biorobotics Conference: Biosignals and Robotics for Better and Safer Living (BRC)*, pages 1–6. IEEE.
- Wu, C.-Y., Ahmed, A., Beutel, A., Smola, A. J., and Jing, H. (2017). Recurrent recommender networks. In *Proceedings of the tenth ACM international conference on web search and data mining*, pages 495–503. ACM.